



Hacettepe Üniversitesi
Fen Fakültesi
İstatistik Bölümü
2024 – 2025 Bahar Dönemi
İST432 Grafiksels Veri Analizi

Hazırlayan Öğrenci:
Zehra Oynaş 2220329027


Ders Sorumlusu:
Dr. Öğr. Üyesi Onur Toka

İçindekiler

Sinaplot	3
Teorik Bilgi	4
Veri Kümesi.....	6
Grafiksel Analiz	9
Sankey / Alluvial Diagram	10
Teorik Bilgi	11
Sankey Veri Kümesi	14
Sankey Grafiksel Analiz	15
Alluvial Veri Kümesi	17
Alluvial Grafiksel Analiz	20
Choropleth Map	21
Teorik Bilgi	22
Veri Kümesi	24
Grafiksel Analiz	25
Kaynakça	27



Sinaplot



Teorik Bilgi

★ Tanım:

Sinaplot, çoklu sınıflara ait tek bir sürekli değişkenin dağılımını görselleştirmek için kullanılan bir veri görselleştirme tekniğidir. Şerit grafik (strip chart) ve keman grafik (violin plot) türlerinden geliştirilmiştir. Bu grafik türü, şerit grafik ve keman grafiklerinin özelliklerini birleştirerek her bir veri noktasını doğrudan gösterirken, yatay eksendeki saçılma (jitter) miktarını, her sınıfın çekirdek yoğunluk tahminine (kernel density estimation) göre ayarlar. Bu sayede, hem veri noktalarının sayısı hem de dağılım yoğunluğu aynı anda görselleştirilmiş olur.

★ Tarihçe:

Sina Plot, 2015 yılında Sina Hadi Sohi tarafından geliştirilmiştir. Sohi, Kopenhag Üniversitesi'nde öğrenci olduğu dönemde, farklı sınıflara ait sürekli değişkenlerin dağılımını daha doğru ve etkili bir şekilde görselleştirmek amacıyla bu grafik türünü tasarlamıştır. Geliştirdiği bu yöntem, daha sonra Nikos Sidiropoulos ve diğer araştırmacılarla birlikte 2017 yılında "SinaPlot: An Enhanced Chart for Simple and Truthful Representation of Single Observations Over Multiple Classes" başlıklı makalede detaylandırılmıştır.

Sina Hadi Sohi'nin bu katkısı, veri görselleştirme alanında önemli bir yenilik olarak kabul edilmekte ve özellikle biyoinformatik ve veri bilimi gibi alanlarda geniş bir uygulama alanı bulmaktadır.

★ Değişken Türü:

Sinaplot, nicel (sürekli) değişkenlerin, nitel (kategorik) sınıflar arasında dağılımını görselleştirmek için uygun olan bir grafik türüdür. Örneğin, farklı tedavi gruplarındaki kan basıncı ölçümleri gibi veriler için idealdir.

★ Kullanım Amacı:

- Her bir sınıftaki veri noktalarının yoğunluk dağılımını ve yayılımını aynı anda gösterdiği için yoğunluk ve dağılımı görselleştirmek amacıyla kullanılabilir.
- Aykırı değerler doğrudan veri noktaları olarak gösterildiğinden, aykırı değerlerin tespit edilmesi amacıyla kullanılabilir.
- Farklı kategorilere ait sürekli değişkenlerin dağılımını karşılaştırmak için idealdir. Bu şekilde çoklu sınıf karşılaştırmaları için kullanılabilir.

★ *Avantajlar:*

- Ortalama, medyan, varyans, yoğunluk dağılımı ve aykırı değerler gibi birçok istatistiksel bilgiyi tek bir grafikte sunar.
- Veri noktaları doğrudan gösterildiğinden, veri kaybı olmadan görselleştirme sağlar.
- Farklı sınıflardaki örneklem büyüklükleri arasındaki farkları açıkça gösterir.
- Sade ve anlaşılır bir görsel sunar.

★ *Dezavantajlar:*

- Çok büyük veri setlerinde, veri noktaları üst üste geleceği için anlaşılabilirlik azalabilir ve yorumlama zorlaşabilir.
- Yoğunluk tahmini için kullanılan parametrelerin (örneğin, bant genişliği) seçimi, grafiğin görünümünü ve yorumunu etkileyebilir.
- Yoğunluk tahminine dayalı saçılma, bazı kullanıcılar için yorumlamayı zorlaştırabilir.

★ *Dikkat Edilmesi Gerekenler:*

- Yoğunluk tahmini için kullanılan bant genişliği, grafiğin pürüzsüzlüğünü ve detay seviyesini etkiler.
- Çok az veri noktası olan sınıflarda, saçılma sınırlı olacağından, yoğunluk bilgisi yeterince temsil edilemeyebilir.
- Farklı sınıfların ayırt edilebilmesi için uygun renk ve sembol seçimleri yapılmalıdır. Kullanılan veri setine bağlı olarak görselde etkisinin fazla olacağı düşünülen renkler kullanılabilir.

Veri Kümesi

Kullanılan veri seti, Kaggle üzerinden alınan "Breast Cancer Gene Expression Profiles (METABRIC)" adlı bir veri setidir. METABRIC (Molecular Taxonomy of Breast Cancer International Consortium) veri seti, meme kanseri hastalarına ait klinik ve genetik bilgileri içermektedir.

Bu raporda sinaplot grafiği için age_at_diagnosis (hastanın teşhis aldığı yaş) ile cellularity (hücre yoğunluğu seviyesi) değişkenleri incelenmiştir. Bu iki değişken, hem görsel analizler açısından uygun yapıda olması hem de tıbbi olarak yorumlanabilirliği yüksek olması nedeniyle seçilmiştir. cellularity değişkeni kategorik (Low, Moderate, High), age_at_diagnosis değişkeni ise sayısal (numeric) bir değişkendir.

Genel Analizler:

Veri setindeki age_at_diagnosis (teşhis yaşı) değişkenine ait temel istatistikler:

Min.	1st Qu.	Median	Mean	3rd Qu.	Max.
21.93	51.45	61.88	61.16	70.65	96.29

Standart sapma: 12.99

cellularity	mean_age	median_age	sd_age
<chr>	<dbl>	<dbl>	<dbl>
1 High	61.2	62.3	13.1
2 Low	59.4	59.2	13.0
3 Moderate	61.6	61.9	12.9

Bireylerin büyük çoğunluğunun 50 ile 70 yaş arasında teşhis aldığını söyleyebiliriz. Ortalama ve medyan birbirine yakın olduğu için yaş dağılımı simetrik sayılabilir. Standart sapmanın yaklaşık 13 olması, yaşlarda orta düzeyde bir yayılım olduğunu gösterir.

Yaş ortalamaları genel bir ifadeyle gruplar arasında yakın görünüyor, Low cellularity grubunun biraz daha düşük yaşta teşhis aldığı görünmektedir. Özellikle medyan ve ortalama yaş farkı Low grubunda daha belirgin. Gruplar arasında yaş ortalamalarının farklı olup olmadığını daha net anlamak için t-testi uygulanmıştır.

High vs Low:

Welch Two Sample t-test

data: age_at_diagnosis by cellularity

$t = 1.8022$, $df = 290.59$, $p\text{-value} = 0.07255$

alternative hypothesis: true difference in means between group High and group Low is not equal to 0

95 percent confidence interval:

-0.1682516 3.8231766

sample estimates:

mean in group High mean in group Low

61.20971 59.38225

- $p\text{-değeri} = 0.072 > 0.05$ olduğundan High ve Low grupları arasında yaş açısından anlamlı bir fark yok.

High vs Moderate:

Welch Two Sample t-test

data: age_at_diagnosis by cellularity

$t = -0.60149$, $df = 1539.9$, $p\text{-value} = 0.5476$

alternative hypothesis: true difference in means between group High and group Moderate is not equal to 0 95 percent confidence interval:

-1.6496762 0.8753739

sample estimates:

mean in group High mean in group Moderate

61.20971 61.59686

- $p\text{-değeri} = 0.548 > 0.05$ olduğundan anlamlı fark yok.

Low vs Moderate:

Welch Two Sample t-test

data: age_at_diagnosis by cellularity

$t = -2.1314$, $df = 316.78$, $p\text{-value} = 0.03382$

alternative hypothesis: true difference in means between group Low and group Moderate is not equal to 0

95 percent confidence interval:

-4.2588874 -0.1703398

sample estimates:

mean in group Low mean in group Moderate

59.38225


61.59686

- $p\text{-değeri} = 0.034 < 0.05$ olduğundan anlamlı fark var

Sadece Low ve Moderate cellularity grupları arasında yaş açısından anlamlı bir fark bulunmuştur. Diğer karşılaştırmalarda farklar istatistiksel olarak anlamlı değildir.

Grafiksel Analiz

Sinaplot Grafiği:



Low hücre yoğunluğu grubunda teşhis yaşının genellikle 50 ile 70 yaş aralığında, Moderate hücre yoğunluğu grubunda teşhis yaşının 50 ile 70 yaş arasında ve High hücre yoğunluğu grubunda ise 40 ile 80 yaş arasında daha yoğun ve diğer iki gruba göre daha geniş bir dağılımı vardır. Ayrıca, 50 ile 70 yaş aralığında Moderate grup, Low gruba göre daha fazla High grup ise her iki gruptan da daha fazla teşhis yoğunluğu içermektedir. Ayrıca High grubunda 20'li yaşlarda bir teşhisin olması aykırı değer olarak söylenebilir.

High hücresel yoğunluk durumlarında teşhis yaşı çok daha geniş bir aralıkta görülürken, Low hücresel yoğunlukta ise daha dar bir aralıkta gerçekleşmektedir. Bu durum, Low yoğunluk grubunda teşhis yaşının High yoğunluğa göre daha öngörülebilir olduğunu göstermektedir.

Ayrıca Low hücresel yoğunluğun simetrik dağıldığı, High hücresel yoğunluğun sağa çarpık bir şekilde dağıldığı ve Moderate hücresel yoğunluğun ise simetriğe daha yakın (Low kadar simetrik değil ama High kadar çarpık da değil) dağıldığı görülmektedir.

Tüm gruplar için 30 yaşından sonra teşhiste belirgin bir artış gözlemlenmektedir. Bu durum, özellikle 30 yaş üstü bireylerin düzenli kontrollerini yaptırmaları gerektiğini göstermektedir. Erken teşhisin önemine dikkat çekmek adına, 30 yaş civarındaki kadınlara yönelik farkındalık kampanyaları, tarama programları ve sağlık eğitimleri gibi uygulamalar artırılmalıdır.

Ayrıca, elimizde aynı bireyin zamanla hücre yoğunluğundaki değişimini izleyebileceğimiz bir veri olsaydı, aynı yaşta zamanla hücresel yoğunluk düzeyinin nasıl değiştiğine dair yorumlar da yapılabilirdi. Ancak elimizdeki veri seti ve grafik uygunluğu açısından, sadece hücresel yoğunluk gruplarında teşhislerin hangi yaş aralıklarında yoğunlaştığı ve hangi yaşlarda başladığı hakkında yorumlar yapıldı.

Alluvial / Sankey Diagram

Alluvial / Sankey Diagram

Teorik Bilgi

★ Tanım:


Alluvial Diyagram: Alluvial diyagramı, kategoriler veya gruplar arasındaki geçişleri, birleşmeleri ve ayrılmaları zaman içinde görselleştirmek için kullanılan bir akış diyagramıdır. Bu diyagramlar, özellikle kategorik değişkenler arasındaki ilişkileri veya zaman içindeki akışları görselleştirmek amacıyla tercih edilir. Bir alluvial diyagramında, bloklar düğüm kümelelerini temsil ederken, bloklar arasındaki akış alanları bu kümelelerin zaman içindeki bileşimlerindeki değişiklikleri gösterir. "Alluvial" terimi, nehirlerin taşıdığı tortuların oluşturduğu "alüvyon yelpazesi"nden ilham alır. S

Sankey Diyagramı: Sankey diyagramı, bir sistemdeki akışların miktarlarını ve yönlerini görselleştirmek için kullanılan bir akış diyagramıdır. Bu diyagramlarda, okların veya çizgilerin genişliği, temsil ettikleri akış miktarıyla orantılıdır. Sistem içinde kaynakların, enerjinin veya bilgilerin nasıl dağıldığını ve nerelerde yoğunlaştığını açıkça gösterir.

Sankey Diyagramı, genellikle daha büyük değerleri daha küçük parçalara bölerek bir değer kümesinden diğerine akışı tasvir etmek için kullanılan bir görselleştirmedir. Bir Alluvial Diyagramı genellikle çoktan çoğa ilişkileri görselleştirir ve birden fazla düğüm veya adım içerebilir.

★ Tarihçe:

Sankey diyagramı adını, İrlandalı kaptan ve mühendis Riall Sankey'den alır. 1898'de [1] buhar makineleri üzerinde çalışırken böyle bir diyagram oluşturdu. Çalışması, ısı kaynağı olan kazandan motorun çeşitli bileşenlerine enerji akışını göstererek buhar makinelerinin verimliliğini görselleştirmeyi amaçlıyordu. Sankey'in okları kullanarak enerji akışını, gölgeli alanların genişliklerinin motorun çevrimi boyunca ısı kaybı miktarına orantılı olarak nasıl gösterdiğini görebiliriz. Bu karmaşık ilişkiler dizisi, basitçe metin ve veri tablolarında sunulsaydı, bir okuyucunun bir bakışta anlaması zor olurdu. En ünlü Sankey diyagramlarından biri Charles Minard'ın 1812 tarihli Napolyon'un Rusya Seferi Haritası'dır. Bu, bir Sankey diyagramının coğrafi bir haritanın üzerine yerleştirildiği bir akış haritasıdır. 1869'da oluşturulmuş olup, Sankey'in 1898 tarihli diyagramından öncedir.



Minutes of Proceedings of The Institution of Civil Engineers, Vol. CXXXIV Session, 1897-98, Part IV

Alluvial diyagramlar ise, ilk kez 2010 yılında Martin Rosvall ve Carl T. Bergstrom tarafından, büyük ölçekli bilimsel atıp ağlarındaki yapısal değişimleri zaman içinde göstermek amacıyla geliştirilmiştir (Rosvall & Bergstrom, 2010). 2011–2015 yılları arasında özellikle sosyal bilimler ve sağlık araştırmalarında, bireylerin zaman içerisindeki grup geçişlerini (örneğin tedavi süreçleri veya sınıflandırma değişimleri) görselleştirmek için kullanılmıştır. 2016 sonrası ggalluvial gibi R paketlerinin geliştirilmesiyle birlikte akademik yayınlarda ve raporlamalarda daha sık tercih edilen bir araç haline gelmiştir. 2019 ve sonrasında ise, açık kaynaklı yazılımların yaygınlaşmasıyla birlikte alluvial diyagramlar; enerji politikaları, nüfus hareketleri, meslek geçişleri, eğitim yapıları gibi pek çok alanda veri analizlerinde yer bulmuştur. (DataVizCatalogue, 2023).

★ *Değişken Türü:*

- Kategorik Değişkenler: Kaynak, hedef, sınıflama gibi ayrımlar
- Nicel Değişkenler: Bu kategoriler arasındaki akışın miktarı (gözlem sayısı, enerji miktarı vb.)
- Her iki diyagram da "kategorik değişkenler arasındaki nicel akışı" gösterir.

★ *Kullanım Amacı:*

- Sınıflamalar, gruplamalar veya kategori geçişlerini izlemek için kullanılır.
- Karmaşık bir sistemi daha kolay anlaşılır hale getirmek, bir sürecin veya sistemin aşamaları boyunca akışların hacmini ve yönünü görsel olarak özetlemek için kullanılır.

★ *Avantajlar:*

- Karmaşık veri akışları sezgisel şekilde gösterilir
- Verimlilik, kayıp, geçiş yapısı gibi önemli bilgiler tek bakışta sunulur
- Etkileşimli yapılarla veri katmanlarına erişim sağlanabilir
- Sankey'in zaman serisi analizlerinde yetersiz kalması durumunda alluvial kullanılabilir.

★ *Dezavantajlar:*

Alluvial / Sankey :

- Fazla kategori olduğunda her iki diyagram da karmaşıklaşabilir
- Akış çizgileri benzer kalınlıktaysa ayırım zor olacağı için yorumlamada net bir kıyaslama yapılamayabilir. Böylece alluvial de sankey de veri setini açıklamada yetersiz kalır.

Alluvial :

- Zaman değişimi için daha uygundur, ancak bazı durumlarda esneklik az olabilir.
- Düzensiz yapıları temsil etmede yetersiz olabilir.
- Etkileşim eksikliği veri analizini zorlaştırır.

Sankey :

- Zaman verileri için yetersiz kalabilir.
- Hikâye anlatımı olmayan verilerde anlamsız olabilir, yorumlama zorlaşır.
- Hiyerarşik veri yapılarında etkisiz olabilir.

★ *Dikkat Edilmesi Gerekenler:*

Çok sayıda düğüm içeren, içe içe giren akışlar içeren yoğun bir diagram karmaşık görüneceğinden mümkün olduğunca bu tür diyagramlardan kaçınılmalıdır. Bu durumlarda düğümler gruplandırılarak grafik sadeleştirilebilir. Gruplandırma da yeterli gelmezse, grafik yerine tablo kullanılması daha uygun olabilir. Akış yönü daima belirgin olmalı (soldan sağa veya yukarıdan aşağı), renkleri ve hizalamaları tutarlı olmalıdır.

Veri Kümesi (Sankey)

Bu çalışmada kullanılan veri seti, Kaggle üzerinden alınan “Urban Wildlife Adaptation Signals” adlı veri setidir. Veri seti, farklı türden yabani hayvanların şehir ortamlarına nasıl adapte olduğunu gözlemleri içermektedir.

Veri setinden hayvan türü (Species) ve gözlem yapılan bölge türü (Location_Type) değişkenleri kullanılmıştır. Bu şekilde, şehirleşmenin yaban hayatı üzerindeki etkilerine, hangi türlerin hangi bölgelerde daha çok bulunduğu bakılmıştır.

Genel Analizler:

	Endüstriyel	Konut	Park	Ticari
Güvercin	90	91	99	88
Rakun	61	51	56	75
Sincap	50	47	49	52
Tilki	45	46	46	54

Güvercin dört mekânda da çok sık gözlenmiş.

Diğer türler benzer sayılarda ve dengeli dağılmış.

Pearson's Chi-squared test

data: table_species_location


X-squared = 4.8446, df = 9, p-value = 0.8476

p-değeri = 0.8476 > 0.05 olduğundan,

Tür (Species) ile bulunduğu mekân (Location_Type) arasında istatistiksel olarak anlamlı bir ilişki yok. Yani türlerin, mekân tercihlerinin rastgele dağıldığını söyleyebiliriz.

Grafiksel Analiz

Sankey Diagram:



Güvercin türünde akışların kalınlığı her dört ortamda da yaygın olarak bulunduğunu gösteriyor. Endüstriyel ve konut alanlardaki akışların diğer türlerin endüstriyel ve konut alanlarındaki akışlarından daha kalın olması sebebiyle güvercin türünün şehirleşmeye en çok adapte olmuş tür olduğu söylenir.

Rakun türünde akışlar birbirine genel olarak benzer görünüyor sadece ticari ve endüstriyel diğer iki mekana göre biraz daha kalın. Böylece rakunun yarı-şehirleşmiş alanları tercih ettiği söylenir.

Sincap türünde göze çarpan farklı bir akış olmadığı için 4 mekanda da bulunduğunu sadece diğer türlere göre bu 4 mekanda en az bulunan iki türden biri olduğu söylenir.

Tilki türü ise sincap gibi 4 mekanda da az bulunan bir tür. En büyük akışın ticari alanında olduğu görülüyor. Gözlemler Sankey diyagramında bazı türlerin bazı mekânlarda daha çok bulunduğunu gösterse de, ki-kare testi bu farkın istatistiksel olarak anlamlı olmadığını ortaya koymuştur

Veri Kümesi (Alluvial)

Bu çalışmada kullanılan veri seti, Kaggle'dan alınan "Global Crude Petroleum Trade (1995–2021)" adlı veri setidir. Veri seti, farklı ülkelerin yıllar içinde gerçekleştirdiği ham petrol ithalat ve ihracat işlemlerini içermektedir. Her bir satır; ülke adı, kıta bilgisi, ticaret türü (ihracat veya ithalat), yıl ve ticaret değeri gibi bilgileri içermektedir. Alluvial diyagramı oluşturmak için üzere veri kümesinde yıllardan sadece 2019, 2020 ve 2021 yılları, ticaret türü (Action), kıta (Continent) ve ticaret değeri (Trade Value) sütunları alınıp bu üç yıl için ihracat ithalat miktarlarına ve kıtalardaki miktarlarına bakıldı.

Genel Analizler:

```
> summary(df_filtered$`Trade Value`)
Min. 1st Qu.  Median    Mean 3rd Qu.   Max.
1.000e+00 4.851e+04 6.130e+07 5.670e+09 1.719e+09 2.080e+11

> mean(df_filtered$`Trade Value`, na.rm = TRUE)
[1] 5669677138

> median(df_filtered$`Trade Value`, na.rm = TRUE)
[1] 61303782

> sd(df_filtered$`Trade Value`, na.rm = TRUE)
[1] 19074652793
```

Ortalama ve medyan arasında çok büyük fark var. Çok büyük ticaret değerleri var. Dağılımın simetrik değil de çarpık olduğunu söyleyebiliriz.

	Year	Mean	Median	SD
	<dbl>	<dbl>	<dbl>	<dbl>
1	2019	6473393476.	56858909	21216005734.
2	2020	4347335641.	73726940	14478312947.
3	2021	6138034533.	59401458.	20631703989.

2020 yılında hem ortalama hem de standart sapma düşmüş.

Action	Mean	Median	SD
<chr>	<dbl>	<dbl>	<dbl>
1 Export	6074654217.	77272955	18168906298.
2 Import	5315322193.	31304584.	19845094482.

Export ortalaması daha yüksek. Ayrıca medyan değeri de daha büyük. Standart sapmaların yüksek olması, export için de import için de ticaret değerlerinin çok değişken olduğunu gösteriyor.

Continent	Mean	Median	SD
<chr>	<dbl>	<dbl>	<dbl>
1 Africa	1828431152.	178140.	6227427522.
2 Asia	10708208771.	258880658.	29533487994.
3 Europe	5318559733.	192246520	14627171849.
4 North America	7320828206.	34999746.	22315714306.
5 Oceania	618144681.	191171	1533419341.
6 South America	2902020409.	277071190	5948396996.

Asya kıtası açık ara en yüksek ortalamaya sahip. Avrupa ve Kuzey Amerika da yüksek, ama Afrika ve Okyanusya'da ticaret hacmi çok düşük. Medyan değerlerin yer yer ortalamalardan yüksek olması da veri dağılımının dengesiz olduğunu gösteriyor.

Welch Two Sample t-test

data: Trade Value by Action

$t = 0.60407$, $df = 911.12$, $p\text{-value} = 0.5459$

alternative hypothesis: true difference in means between group Export and group Import is not equal to 0

95 percent confidence interval:

-1707670163 3226334211

sample estimates:

mean in group Export mean in group Import

6074654217 5315322193

$p\text{-değeri} = 0.5459 > 0.05 \rightarrow$ Export ve Import işlemlerinin ortalama ticaret değerleri arasında istatistiksel olarak anlamlı fark yoktur.

	Df	Sum Sq	Mean Sq	F value	Pr(>F)
Continent	5	1.157e+22	2.314e+21	6.552	5.33e-06 ***
Residuals	909	3.210e+23	3.531e+20		

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

p-değeri = 5.33e-06 < 0.05 → İstatistiksel olarak anlamlı!

Kıtalar arasında ticaret değerleri açısından anlamlı farklar bulunmaktadır.

```
> table(df_filtered$Year, df_filtered$Action)
```

	Export	Import
2019	142	166
2020	138	159
2021	147	163

```
> table(df_filtered$Action, df_filtered$Continent)
```


	Africa	Asia	Europe	North America	Oceania	South America
Export	102	118	112	48	17	30
Import	114	120	115	64	43	32

Üç yıl boyunca ithalat (Import) işlem sayısı, ihracat (Export) işlem sayısından biraz daha fazla olmuştur. Genel olarak işlem sayıları yıllar arasında dengeli dağılmıştır.

Tüm kıtalarda hem ihracat hem ithalat işlemleri yapılmış, en yoğun işlemler Asya ve Avrupa kıtalarında gerçekleşmiştir.

Grafiksel Analiz

Alluvial Diagram:



Year → Action kısmı:

2019 yılında Export hacmi, Import'a göre daha yüksek görünüyor; 2020'de Export ve Import arasında yakın miktarlar olduğu görünüyor; 2021'de ise Import oranının tekrar yükseldiği görünüyor. 2020 yılında 2019 yılına göre olan düşüşün en büyük sebebinin Covid-19 pandemisi olması düşünülür. Pandeminin ne kadar süreceğinin belirsiz olmasından dolayı olan ekonomik belirsizlikler, ihracat-ithalat dengesinin değişmesine de neden oldu. Dünya genelindeki enerji ticaretini de etkilediği görülür. Petrol dağıtımında da bu pandeminin krizlerinin etkisinin hemen hissedilmeye başlandığı görülüyor. Pandeminin etkisi hissedilmeye başlandığında, ellerdeki petrol satılamadı ve stoklarda kaldı. Üretim ise henüz durdurulmadığı için pandeminin ne kadar devam edeceği vs bilinmediği için bir süre daha petrol çıkarılmaya devam edildi ve bu da petrol fazlasına neden oldu. Bu durum da fiyatların düşmesine neden oldu.. Fiyatların düşmesiyle birlikte, bazı ülkeler ihraç ettikleri petrol miktarlarını azaltmaya gitmiş olabilir. Ayrıca 2020 döneminde dünya gündemine gelmeye başlayan yenilenebilir enerji politikaları, yeni dünya düzeninde enerjiler ve bunların reklamları, petrol ithalatının düşmesine sebep olmuş olabilir. 2021 yılına gelindiğinde ise pandeminin etkisinin azalması, aşının bulunmasıyla turizm ve seyahatlerin canlanmasıyla birlikte petrol ticareti tekrar artmaya başlamış olabilir.

Action → Continent kısmı:

Hem ithalat (Import) hem de ihracat (Export) akışlarının en çok Asia ve Europe kıtalarında olduğu görülüyor. Africa da belirgin bir paya sahipken, Americas (N. ve S. America) kıtalarına yapılan ticaretin diğerlerine göre daha az olduğu görülüyor. Yani petrol ticaretinde en büyük akışlar Asya ve Avrupa merkezli gerçekleştiği söylenir.

Açıklama:

Year → Action → Continent eksenlerine sahip bir alluvial diyagram oluşturmayı hedefledim. Amacım 2019, 2020 ve 2021 yıllarından hem ihracat (Export) hem de ithalat (Import) kutularına toplam ticareti tek bir akışla sağlamak sonrasında da import ve export için toplam ticaretin kıtalara nasıl dağıldığını yine tek akışlı şekilde göstermekti.

Ancak, hem Year → Action arasında hem de Action → Continent arasında bunu sağlayamadım. Year → Action arasında tek akışları yapabildiğimde Action → Continent arasında tek akışları elde edemedim. Action → Continent arasında tek akışları yapabildiğimde Year → Action arasında tek akışları elde edemedim. Son aşamada yani eklenen grafikte;

Import → Asia arasında 3 akış var ama burada da tek akış olmalıydı.

Import → Europe arasında 3 akış var ama burada da tek akış olmalıydı.

Bu sorunu çözmek için önce Year → Action kısmındaki çoklu akışları azaltmayı denedim. Bunun için aynı yıl içinde gerçekleşen tüm ithalat veya ihracat işlemlerinin ticaret değerlerini birleştirip tek bir değere indirgedim. Yani örneğin 2019 yılında farklı kıtalara yapılan tüm “Export” işlemlerini tek bir toplam değer olarak ele alarak, 2019’dan sadece tek bir Export akışı çıkması için veriyi bu şekilde yeniden düzenledim.

Ancak bunu yaptığımda bu kez Action → Continent kısmında yine çok sayıda ayrı akış oluştu. Çünkü Export kutusundan farklı kıtalara yapılan işlemler hala ayrı satırlarda olduğu için, her bir kıtaya giden ayrı bir çizgi oluşuyordu. Bu durumu düzeltmek için bu kez de Export ve Import işlemlerinin her biri için ilgili kıtalara yapılan ticaret değerlerini bir araya getirip Export → Asia, Export → Europe gibi yönlerde sadece tek bir değer olacak şekilde düzenleme yaptım. Ancak bu sefer de en baştaki Year → Action kısmı bozuldu ve yine birden fazla akış görünmeye başladı. İki farklı alluvial elde edip birleştirmeyi denediğimde de görsel açıdan uygun olmadı.

Yani her seferinde bir eksen düzelttiğimde, diğer eksenlerde tekrar çoklu akışlar oluştu. Sürekli olarak iki eksen arası akışı düzeltirken, üçüncü eksen karışıyordu. Düzeltmeye çalıştığım alanlar sırayla bozuluyordu. Bu nedenle oluşturmam gereken grafiği oluşturamadım.

Boş kutuları önlemek için `geom_stratum()` ve `geom_text()` fonksiyonlarında sadece belirli eksenlere ait veri satırlarını filtreleyerek göstermeyi denedim. Örneğin sadece `!is.na(Year)` olanları `axis1` için, `!is.na(Continent)` olanları `axis3` için kullandım. Bu bazı durumlarda işe yaradı ama `ggalluvial` paketi arkada otomatik olarak eksenleri oluşturduğu için tüm boşluklar temizlenemedi.



Choropleth Map

Choropleth Map

Teorik Bilgi

★ Tanım:


Choropleth map (Antik Yunanca $\chi\omicron\rho\omicron\varsigma$ (*khôros*) ' alan, bölge ' ve $\pi\lambda\eta\theta\omicron\varsigma$ (*plêthos*) ' çokluk ' kelimelerinden) nüfus yoğunluğu veya kişi başına düşen gelir gibi mekansal sayım birimleri içindeki coğrafi bir özelliğin toplu özetine karşılık gelen renk anlamına gelen pseudocolor kullanan bir tür istatistiksel tematik haritadır.

Choropleth map, bir değişkenin coğrafi bir alanda nasıl değiştiğini görselleştirmenin veya bir bölge içindeki değişkenlik düzeyini göstermenin kolay bir yolunu sunar. Choropleth muhtemelen en yaygın tematik harita türüdür çünkü yayınlanmış istatistiksel veriler genellikle ülkeler, eyaletler, iller ve ilçeler gibi iyi bilinen coğrafi birimlere toplanır ve bu nedenle GIS , elektronik tablolar veya diğer yazılım araçları kullanılarak oluşturulması nispeten kolaydır.

Yapı: Bir choropleth haritası iki veri kümesini bir araya getirir: Coğrafi alanın ayrı bölgelere bölünmesini temsil eden mekansal veriler.

★ Tarihçe:

- Bilinen en eski koroplet haritası, 1826 yılında, matematikçi, mühendis, ekonomist ve Fransız politikacı Baron Charles Dupin, bölgelerin renklerle ya da desenlerle doldurularak "nüfus yoğunluğu ya da kişi başına düşen gelir gibi istatistiksel bir ölçüyü" gösterdiği tematik harita türü olan "Carte tintée"yi icat etti. Dupin bu haritayı ilk kez 1826 yılında "Carte figurative de l'instruction populaire de la France" (Fransa'da Halk Eğitimi Haritası) adlı haritasında uyguladı. Bu haritayı bir yıl sonra "Forces productives et commerciales de la France" (Fransa'nın Üretici ve Ticari Güçleri) adlı kitabında yayımladı.
- "Koroplet harita" terimi 1938'de coğrafyacı John Kirtland Wright tarafından ortaya atıldı ve 1940'lara gelindiğinde kartograflar arasında yaygın olarak kullanılmaya başlandı. Ayrıca 1938'de Glenn Trewartha bunları "oran haritaları" olarak yeniden ortaya attı ancak bu terim varlığını sürdüremedi.



★ *Değişken Türü:*

- Choropleth haritalar sürekli (nicel) ve özellikle oran veya yoğunluk tipi verilerle en verimli şekilde çalışır.

★ *Kullanım Amacı:*

- Choropleth haritalar, belirli bir değişkenin coğrafi bölgeler üzerindeki dağılımını renk tonları aracılığıyla görselleştirerek mekansal desenleri ve bölgesel farklılıkları ortaya koyar. Bu sayede, sosyal, ekonomik veya çevresel göstergelerin bölgeler arasında karşılaştırılması mümkün hale gelir. Aynı zamanda politika yapıcılar için önemli bir karar destek aracı işlevi görerek kaynakların daha etkili ve hedefli biçimde yönlendirilmesine katkı sağlar. Choropleth haritalar zaman serileriyle birlikte kullanıldığında ise, belirli bir göstergenin yıllar içindeki mekansal değişimini izleme ve değerlendirme imkânı sunar.

★ *Avantajlar:*

- Görsel Anlaşılabilirlik: Choropleth haritalar, istatistiksel verilerin coğrafi bölgeler üzerindeki dağılımını renk tonlarıyla göstererek, verilerin kolayca anlaşılmasını sağlar.
- Mekansal Örüntülerin Tespiti: Bu haritalar, belirli bir değişkenin coğrafi bölgeler üzerindeki dağılımını görselleştirerek, mekansal örüntülerin ve bölgesel farklılıkların kolayca fark edilmesini sağlar.

★ *Dezavantajlar:*

- Büyük Alanların Aşırı Vurgulanması: Geniş yüzölçümüne sahip bölgeler, daha küçük ancak yoğun veriye sahip bölgelerden daha fazla dikkat çekebilir, bu da verinin yanlış yorumlanmasına neden olabilir.
- Sınır Etkisi ve Ani Geçişler: Komşu bölgeler arasında renk tonlarındaki ani değişiklikler, veride olmayan keskin sınırlar algılanmasına yol açabilir.
- Veri Sınıflandırma Sorunları: Verilerin sınıflandırılması sırasında seçilen yöntem (örneğin, eşit aralık, çeyrekler, doğal kırılmalar) haritanın yorumunu etkileyebilir ve farklı sonuçlara yol açabilir.
- Toplam Değerlerin Kullanımı: Toplam değerlerin doğrudan kullanılması, nüfus veya alan büyüklüğü gibi faktörleri göz ardı ederek yanıltıcı sonuçlar doğurabilir.

★ Dikkat Edilmesi Gerekenler:

- Verilerin karşılaştırılabilir olması için, toplam değerler yerine oranlar veya yoğunluklar kullanılmalıdır. Örneğin, toplam nüfus yerine nüfus yoğunluğu (kişi/km²) tercih edilmelidir.
- Veri ve harita farklı düzeylerdeyse (örneğin veri "bölge", harita "il") yanlış ve yanıltıcı bir grafik oluşur. Bu nedenle veri ile harita geometrisinin aynı düzeyde (aynı granüleritede) olması zorunludur.

(Marco Cremonini'nin *Data Visualization in R and Python* (2024))

- Renk Paleti Seçimi: Renk tonları, verinin anlamını doğru yansıtacak şekilde seçilmelidir. Sıralı veriler için tek renk tonları, iki uçlu veriler için diverging paletler kullanılabilir.

Veri Kümesi

Bu çalışmada kullanılan veri seti, TÜİK'ten alınan illere göre ortalama eğitim süresi verisidir. 2023 yılına ait analiz yapılacağı için, veri setinden sadece 2023 yılına ait toplam (kadın + erkek) ortalama eğitim süresi sütunu kullanılmıştır. Veriler R programında tmap paketi ile görselleştirilmiş ve Türkiye'de illere göre ortalama eğitim süresi choropleth harita ile gösterilmiştir.

Genel Analizler:

```
> mean(egitim$toplam)
[1] 8.882716
> median(egitim$toplam)
[1] 8.9
> sd(egitim$toplam)
[1] 0.5731034
> summary(egitim$toplam)
Min. 1st Qu. Median Mean 3rd Qu. Max.
7.400 8.500 8.900 8.883 9.300 10.700
> shapiro.test(egitim$toplam)

Shapiro-Wilk normality test
```

data: egitim\$stoplam

W = 0.98659, p-value = 0.5636


2023 yılına ait illere göre ortalama eğitim süresi verileri üzerinde yapılan açıklayıcı analizlerde, ortalamanın 8.88 yıl ve medyanın 8.90 yıl olduğu görülmüştür. Veriler, düşük bir standart sapma ile (0.57) oldukça simetrik dağılmıştır.

Shapiro-Wilk testi ile yapılan normallik analizinde (W = 0.987, p = 0.564) p-değerinin 0.05'ten büyük olması, verilerin normal dağılım varsayımını sağladığını göstermektedir.

Grafiksel Analiz

Choropleth Map Grafiği:

İllere Göre Ortalama Eğitim Süresi - 2023



En yüksek ortalama eğitim süresine sahip ilin İç Anadolu Bölgesi'nden Ankara olduğu görülmektedir. Ankara, 10.5 yıl ve üzeri ortalama eğitim süresiyle Türkiye'de ilk sırada yer almaktadır.

Ankara'yı 10–10.5 yıl aralığıyla İstanbul takip etmektedir. Bu illerin ardından öne çıkan diğer iller arasında Eskişehir, İzmir, Antalya, Muğla ve bulunduğu bölgede dikkat çeken Hakkari yer almaktadır.

Bölgesel olarak bakıldığında, Ege, Akdeniz ve Marmara bölgelerinin genel olarak orta tonlarla, yani 8.5–9.5 yıl arası eğitim süresine sahip oldukları görülmektedir. Karadeniz, Güneydoğu ve Doğu Anadolu Bölgeleri’nde eğitim sürelerinin çoğunlukla 8.0–9.0 yıl aralığında yoğunlaştığı görülmektedir.

Özellikle Hakkari’nin, Doğu Anadolu Bölgesi’nde yer almasına rağmen 9.0–9.5 yıl aralığında yer alması, bölge ortalamasının üzerinde bir eğitim süresine sahip olması açısından önemlidir. Bu durumla ilgili, bölgedeki eğitim olanaklarını artırmaya yönelik çalışmaların ilk olarak Hakkari’de uygulanmaya başlandığı ve burada elde edilen olumlu sonuçların ve artışların bölge geneline yayılacak politikalarda referans olacağı düşünülebilir.

Ayrıca son yıllarda yaşanan ekonomik olumsuzluklar, alım gücünün azalması ve yoksulluğun artmasıyla birlikte bazı çocukların iş hayatına atılmak için okuldan ayrılıp eğitim hayatlarını yarıda bırakmak zorunda kalmaları da ortalama eğitim süresinin düşük olmasının sebeplerinden biri olabilir.

Kaynakça

<https://www.tandfonline.com>

<https://rpubs.com>

<https://www.epirhandbook.com/en/>

<https://www.historyofinformation.com>

<https://www.geeksforgeeks.org>

<https://tr.wikipedia.org/wiki/Anasayfa>

<https://www.veribilimiokulu.com>

<https://bookdown.org>

<https://visiochart.com>

<https://datavizcatalogue.com>

<https://data.europa.eu/apps/data-visualisation-guide/dataviz-catalogue>

<https://flowingdata.com/2012/11/12/how-to-make-and-interactive-choropleth-map/>

<https://onlinelibrary.wiley.com>

Mihaljević, B., Milinković, T., & Milinković, M. (2017). Alluvial plots: A visualization tool for multivariate categorical data. *Journal of Computational and Graphical Statistics*, 26(3), 445–456.

Marco Cremonini'nin *Data Visualization in R and Python* (2024))

Veri Setleri

<https://www.kaggle.com/datasets/toriquelstu/global-crude-petroleum-trade-1995-2021>

<https://www.kaggle.com/datasets/efeyldz/urban-wildlife-adaptation-signals-dataset>

<https://www.kaggle.com/datasets/raghadalharbi/breast-cancer-gene-expression-profiles-metabric>

TUIK. (2023). *İllere Göre Ortalama Eğitim Süresi*.